作业内容

1 使用 InternLM-Chat-7B 模型生成 300 字的小故事

2 熟悉 hugging face 下载功能,使用 huggingface_hub python 包,下载 InternLM-20B 的 config.json 文件到本地 (需截图下载过程)。

2.1 服务器

白嫖版google colab

2.2 下载代码

1. ModelScope下载

```
# snapshot_download下载方法,链接魔塔社区

import torch
from modelscope import snapshot_download, AutoModel, AutoTokenizer
import os
model_dir = snapshot_download('Shanghai_AI_Laboratory/internlm-chat-20b', cache_dir='/root/model', revision='v1.0.3')
```

2. Huggingface下载 (失败)

```
# huggingface 下载方法,但是InternLM用这种方法下载似乎会失败: HTTPError: Response
    details: {'Code': 10010205001, 'Message': '获取模型版本失败, 信息: record not
    found', 'Requestid': '3a020967-3af6-401c-9a24-9cc8b73cb7e5', 'Success':
    False}, Request id: d410724cfe7542d5930d3aaa4d4eb803
2
3
   import torch
4
    from transformers import AutoTokenizer, AutoModelForCausalLM
   tokenizer = AutoTokenizer.from_pretrained("internlm/internlm-chat-20b",
    cache_dir='/root/model', trust_remote_code=True)
    # Set `torch_dtype=torch.bfloat16` to load model in bfloat16, otherwise it
    will be loaded as float32 and cause OOM Error.
    model = AutoModelForCausalLM.from_pretrained("internlm/internlm-chat-20b",
    torch_dtype=torch.bfloat16, trust_remote_code=True).cuda()
   model = model.eval()
   output, history = model.chat(tokenizer, "Hello! Today is sunny, it is time
   to go out")
10
   print(output)
11 | # Hello! Today is sunny, and it sounds like a great day to go out an enjoy
    the weather. What would you like to do?
```

3. huggingface_hub下载

```
    # 可以继续未完成的下载过程,并保存到本地目录/content/model
    huggingface-cli download --resume-download internlm/internlm-20b --local-dir /content/model
```

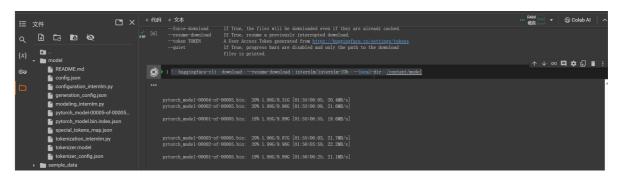
4. openxlab镜像下载:

```
from openxlab.model import download
download(model_repo='OpenLMLab/InternLM-20b', model_name='InternLM-20b',
output='/content/model', overwrite='No')
```

5. 手动下载: 在抱抱脸上直接找到模型权重文件, 摁下。

2.3 下载结果

huggingface_hub下载 (config.json):



2.4 关于huggingface下载的知识延伸

1. ModelScope下载 (snapshot_download):

官方链接: HfApi Client (huggingface.co)

- 1. 通常是国内源下载。
- 2. 比较了令人困惑的是repo_id,可以在这里了找到:

 书生·浦语-对话-20B
 Shanghai_Al_Laboratory/internIm-chat-20b

 ● 模型介绍
 模型文件
 ☑ 提交反馈
 Notebook快速开发

3. cache_dir:模型保存位置,建议设置。

2. huggingface-cli下载:

这是一个多层的参数结构:

先看看 `huggingface-cli --help:

```
usage: huggingface-cli <command> [<args>]
 2
 3
    positional arguments:
      {env,login,whoami,logout,repo,upload,download,lfs-enable-largefiles,lfs-
    multipart-upload, scan-cache, delete-cache}
 5
                             huggingface-cli command helpers
                             Print information about the environment.
 6
        env
 7
        login
                             Log in using a token from
    huggingface.co/settings/tokens
                             Find out which huggingface.co account you are logged
        whoami
    in as.
 9
        logout
                             Log out
10
        repo
                             {create} Commands to interact with your
    huggingface.co repos.
        upload
                             Upload a file or a folder to a repo on the Hub
11
12
        download
                             Download files from the Hub
13
        lfs-enable-largefiles
                             Configure your repository to enable upload of files
14
    > 5GB.
                             Scan cache directory.
15
        scan-cache
16
        delete-cache
                             Delete revisions from the cache directory.
17
    options:
18
      -h, --help
                             show this help message and exit
19
```

再看看 `huggingface download --help。这里的**positional arguments**不需要带关键字,且**顺序不可变**。其中repo_id是huggingface的model中的仓库路径,如**internlm/internlm-20b**:

created, no matter the file size. If set to `False`,

symlink will be

the file will either

35

```
36
                            be duplicated from cache (if already exists) or
    downloaded from the Hub
37
                            and not cached.
                           If True, the files will be downloaded even if they
38
      --force-download
    are already cached.
                          If True, resume a previously interrupted download.
39
     --resume-download
40
     --token TOKEN
                           A User Access Token generated from
    https://huggingface.co/settings/tokens
41
    --quiet
                           If True, progress bars are disabled and only the
    path to the download
42
                           files is printed.
```

3. openxlab镜像下载:

文档: <u>Download Models | Docs-OpenXLab</u>

无他,就是要配置一下AK和SK,根据<u>教程</u>走一遍就好。当然这个配置过程在google colab上可能有些繁琐,不是很建议。其他的服务器可以一试。

ps: 这里挖个坑

3 完成浦语·灵笔的图文理解及创作部署 (需截图)

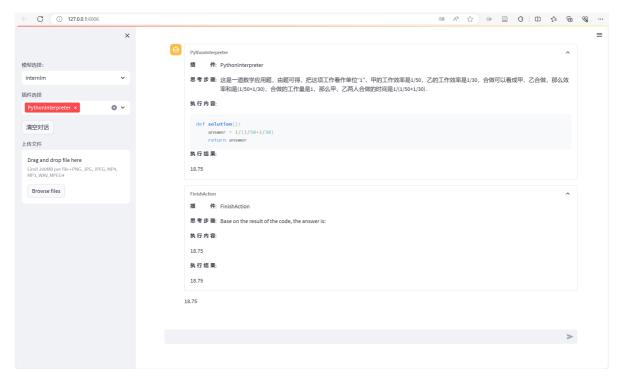
3.1 运行命令 (环境配置略,直接参考链接):

```
conda activate internlm-demo
streamlit run /root/code/lagent/examples/react_web_demo.py --server.address
127.0.0.1 --server.port 6006
```

3.2部署情况:

先来一道简单的初中数学题:

1 请解下面这一道初中数学题:将一批数据输入电脑,甲独做需要50分钟完成,乙独做需要30分钟完成,现在甲独做30分钟,剩下的部分由甲、乙合做,问甲、乙两人合做的时间是多少?

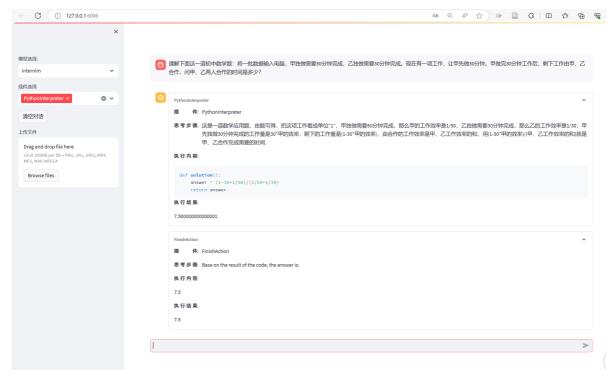


仁慈的我只让它写了一道初中数学题, 然鹅这道题答案是 7.5, 书生解错了。我们看看书生的解题步骤:

1 这是一道数学应用题,由题可得,把这项工作看作单位"1",甲的工作效率是1/50,乙的工作效率是1/30,合做可以看成甲、乙合做,那么效率和是(1/50+1/30),合做的工作量是1,那么甲、乙两人合做的时间是1/(1/50+1/30).

看上去是自然语言理解的问题,似乎书生不能理解"甲单独做,剩下的"这一部分逻辑。那我们对题干稍 作改进:

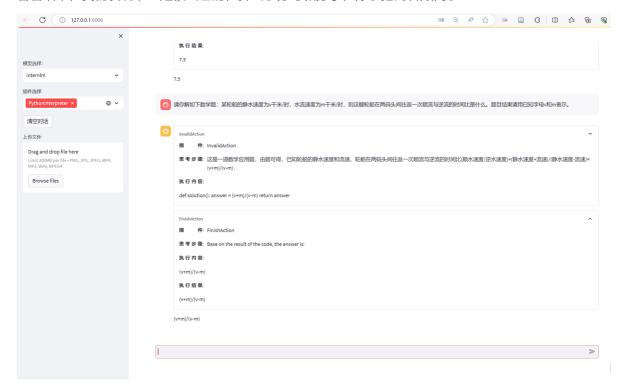
1 请解下面这一道初中数学题:将一批数据输入电脑,甲独做需要50分钟完成,乙独做需要30分钟完成。现在有一项工作,让甲先做30分钟。甲做完30分钟工作后,剩下工作由甲、乙合作,问甲、乙两人合作的时间是多少?



不愧是我,那我们再尝试一道应用题,这次换一道偏代数的题目:

1 请你解如下数学题:某轮船的静水速度为v千米/时,水流速度为m千米/时,则这艘轮船在两码头间往返一次顺流与逆流的时间比是什么。题目结果请用已知字母v和m表示。

看看结果,我们发现书生是很出色的,算出了分母和分子,除了把两者颠倒了:



我们来看看书生的思考过程:

1 这是一道数学应用题,由题可得,已知轮船的静水速度和流速,轮船在两码头间往返一次顺流与逆流的时间比(顺水速度/逆水速度)=(静水速度+流速)/(静水速度-流速)=(v+m)/(v-m).

看来是误解了时间比和速度,那么我们继续refine一下题干:

1 请你解如下数学题:某轮船的静水速度为v千米/时,水流速度为m千米/时,则这艘轮船在两码头间往返一次顺流与逆流的所消耗的时间之比是什么。提示:消耗的时间和船的速度呈现反比关系。题目结果请用已知字母v和m表示。

看看结果,通过引入所消耗时间这一物理概念,书生似乎理解了提议。但是这个0.666666...67是什么鬼?为什么你的最终总结是个整数??????

⑥ 请你解如下数学题:某轮船的静水速度为√干米/时,水流速度为m干米/时,则这艘轮船在两码头间往返一次顺流与逆流的所消耗的时间之比是什么。提示:消耗的时间和船的速度呈 现反比关系。题目结果请用已知字母v和m表示。 PythonInterpreter 插 件: PythonInterpreter 思考步骤: 这是一道数学题,需要用计算器来计算一下消耗的时间之比。 def solution(): answer = 1/((v+m)/(v-m))return answer 件: PythonInterpreter 思考步骤: 我之前的代码有误,需要重新输入。 def solution(): answer = 1/((v+m)/(v-m))return answer 件: PythonInterpreter 思考步骤: 我之前的代码有误, 需要重新输入。 执行内容: def solution(): v = 10 answer = 1/((v+m)/(v-m))0.666666666666666 FinishAction 插 件: FinishAction 思考步骤: Base on the result of the code, the answer is: 这艘轮船在两码头间往返一次顺流与逆流的所消耗的时间之比是0.67。

这艘轮船在两码头间往返一次顺流与逆流的所消耗的时间之比是0.67。

这艘轮船在两码头间往返一次顺流与逆流的所消耗的时间之比是0.67。

3.3 一点小总结

觉得自己像在教一个笨学生,不是他数学不好,而是: **(1) 语文没学好; (2) 缺乏对基本的物理概念,或者往更广的方面说,理工科概念,的认识。**

从本次实践的少量样本看,可以得出一个不成熟的结论:如果要提升大模型的数理能力,有以下一些努力方向。

- 1. 数据方面:提升模型对于有噪音输入的理解能力。自然语言的表达是极为灵活的,数学题的题干也不能避免。试想一下,如果InternLM投入商用,你并不能保证输入的每条题干都表达都具备LLM视角的严谨规范。(非结构化->结构化?)
- 2. 知识方面: Lagent的逻辑能力还是不错的,但是实践中未能区分一些基本概念(比如时间和速度)。如何更好在NLP过程中引入相关概念知识,也是一个努力方向。
- 3. Prompt方面: 其实题干不是这样的,都是我加了很多提示,比如果针对代数题,我添加了题目结果请用已知字母v和m表示的提示词。如果没有加这句,结果是十分离谱的(他给了"-1"的答案)。所以如何针对不同题型设计提示词,引导智能体生成符合预期的结果,也是一个值得研究的方向。

4 完成 Lagent 工具调用 Demo 创作部署 (需截图)

4.1 运行命令 (环境配置略,直接参考链接):

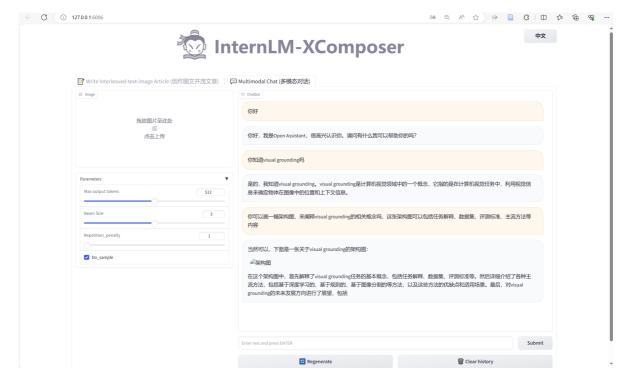
```
conda activate xcomposer-demo
cd /root/code/InternLM-XComposer
python examples/web_demo.py \
--folder /root/model/Shanghai_AI_Laboratory/internlm-xcomposer-7b \
--num_gpus 1 \
--port 6006
```

4.2 部署情况:

文章创作:



多模态对话:



我的期待是不是太高了一些。。。

报错

1服务器第二次链接报错

报错信息:

- 1 > The ECDSA host key for [ssh.intern-ai.org.cn]:34314 has changed,
- 2 > and the key for the corresponding IP address [8.130.47.207]:34314
- 3 > has a different value. This could either mean that
- 4 > DNS SPOOFING is happening or the IP address for the host
- 5 > and its host key have changed at the same time.

错误分析:

在known_hosts文件中的缓存,再一次配置ssh时就当前新加节点的IP和known_hosts文件IP冲突,导致报错。

解决方案:

1 ssh-keygen -R [服务器ip]

如果不晓得服务器ip,直接将.ssh/known_hosts中的内容删除,就可以重新连接。